

Contrôle Qualité Industriel

Détection de Défauts de Surface sur Pièces
Métalliques par CNN Interprétable

Module	Deep Learning
Dataset	NEU Surface Defect Database
Classes	6 types de défauts — 1440 images
Précision	99.07% sur le jeu de test
Outils	TensorFlow / Keras, Grad-CAM, t-SNE, Gradio
Encadrante	Mme Souhir MABROUK

1. Introduction et Contexte

Dans l'industrie manufacturière, le contrôle qualité des pièces produites est une étape critique qui garantit la conformité aux standards de production. Traditionnellement effectué par inspection visuelle humaine, ce processus est coûteux, subjectif et ne peut pas opérer en continu sur les lignes de production à haut débit.

L'automatisation de cette tâche par vision par ordinateur et Deep Learning représente un enjeu majeur pour l'Industrie 4.0. Ce projet vise à développer un système de détection de défauts de surface sur des pièces métalliques (acier inoxydable, aluminium) à partir d'images de surface acquises par caméras industrielles.

Objectif principal : Concevoir un CNN interprétable capable de classifier automatiquement 6 types de défauts de surface avec une précision supérieure à 95%, et d'expliquer ses décisions grâce à Grad-CAM.

1.1 Objectifs pédagogiques

Ce projet couvre les objectifs suivants :

- Développer un pipeline de traitement d'images industrielles en niveaux de gris avec augmentation spécifique aux défauts de surface.
- Construire et optimiser une architecture CNN from scratch adaptée à la détection de défauts subtils.
- Mettre en oeuvre une approche de réseau siamois pour comparer des patches d'image sans défaut avec des patches défectueux.
- Utiliser Grad-CAM pour interpréter les décisions du modèle et identifier les zones les plus influentes.
- Comparer les performances avec et sans augmentation, et analyser les types de défauts les plus difficiles à classifier.
- Proposer une interface web de démonstration reliée au modèle entraîné.

2. Dataset — NEU Surface Defect Database

Le dataset NEU Surface Defect Database est une référence dans le domaine de la détection de défauts industriels. Il contient 1800 images de surface d'acier réparties en 6 classes de défauts, chaque classe contenant exactement 300 images.

2.1 Caractéristiques du dataset

Caractéristique	Valeur
Nombre total d'images	1800 (train + validation)
Images utilisées	1440 images (ensemble train)
Taille originale	200 × 200 pixels
Taille redimensionnée	224 × 224 pixels
Mode colorimétrique	Niveaux de gris (1 canal)
Classes	6 types de défauts
Images par classe	300 (dataset équilibré)

2.2 Description des 6 classes de défauts

Classe	Description	Caractéristiques visuelles
Crazing	Fissures réseau	Micro-craquelures distribuées sur toute la surface
Inclusion	Inclusions	Particules étrangères incrustées dans le métal
Patches	Taches	Zones décolorées ou textures irrégulières
Pitted Surface	Surface piquée	Petits cratères ou trous distribués
Rolled-in Scale	Écailles incrustées	Lamelles de métal soulevées ou incrustées
Scratches	Rayures	Lignes profondes linéaires sur la surface

2.3 Préparation des données

Les images ont été prétraitées selon les étapes suivantes :

- Chargement en niveaux de gris avec OpenCV (cv2.IMREAD_GRAYSCALE)
- Redimensionnement à 224×224 pixels pour compatibilité avec les filtres standards
- Normalisation Min-Max : pixels [0, 255] → [0.0, 1.0]

- Ajout de la dimension canal : forme finale (224, 224, 1)
- Encodage One-Hot des labels pour la classification multi-classes
- Division stratifiée : 70% train (1008) / 15% validation (216) / 15% test (216)

Pourquoi la stratification ? La stratification garantit que chaque classe est représentée proportionnellement dans chaque ensemble (train/val/test), évitant ainsi un déséquilibre artificiel lors de l'évaluation.

3. Pipeline d'Augmentation de Données

L'augmentation de données est une technique de régularisation qui augmente artificiellement la diversité du dataset d'entraînement, améliorant ainsi la capacité de généralisation du modèle.

3.1 Techniques appliquées

Technique	Paramètres	Justification industrielle
Rotation	$\pm 10^\circ$ (0.05 en fraction)	Les pièces métalliques sont généralement alignées sur la chaîne
Translation	$\pm 8\%$ (horizontal et vertical)	Simule un léger décalage de la caméra industrielle
Zoom	[0.95, 1.05]	Simule les variations de distance entre capteur et pièce
Bruit Gaussien	$\sigma \in [0.01, 0.03]$	Simule le bruit thermique des capteurs industriels
Bruit Sel-et-Poivre	$p = 0.02$	Simule les artefacts électroniques des capteurs
Cutout	20×20 px, $p = 0.4$	Simule une occlusion partielle de la surface métallique

3.2 Justification du rejet du flip horizontal

Pourquoi nous n'utilisons PAS le flip horizontal ?

Dans un contexte industriel, un défaut de surface orienté (comme une rayure ou une écaille incrustée) a une signification physique liée à son orientation. Un flip horizontal transformerait artificiellement la direction du défaut, créant des images qui ne correspondent à aucun défaut réel observé en usine. De même, une forte rotation ($>15^\circ$) est inappropriée car les pièces métalliques sont généralement alignées de manière constante sur les lignes de production.

4. Architecture CNN

Nous avons conçu une architecture CNN from scratch composée de 4 blocs convolutifs avec un nombre croissant de filtres, suivis d'une tête de classification avec GlobalAveragePooling.

4.1 Structure de l'architecture

Composant	Détails	Paramètres
Entrée	224 × 224 × 1 (niveaux de gris)	—
Bloc 1	Conv2D(32) + BN + ReLU + MaxPool(2×2) + Dropout(0.3)	320
Bloc 2	Conv2D(64) + BN + ReLU + MaxPool(2×2) + Dropout(0.3)	18 496
Bloc 3	Conv2D(128) + BN + ReLU + MaxPool(2×2) + Dropout(0.3)	73 856
Bloc 4	Conv2D(256) + BN + ReLU + MaxPool(2×2) + Dropout(0.3)	295 168
GAP	GlobalAveragePooling2D	0
Dense 1	Dense(128, ReLU) + Dropout(0.5)	32 896
Sortie	Dense(6, Softmax)	774
TOTAL	1 430 470 paramètres entraînables	—

4.2 Choix de conception

- **BatchNormalization** : Stabilise l'apprentissage en normalisant les activations à chaque couche, permettant un learning rate plus élevé et une convergence plus rapide.
- **Dropout(0.3) après chaque bloc** : Régularisation pour éviter le surapprentissage en désactivant aléatoirement 30% des neurones pendant l'entraînement.
- **GlobalAveragePooling2D** : Remplace Flatten(), réduisant drastiquement le nombre de paramètres et améliorant la généralisation.
- **Filtres croissants (32→256)** : Les premières couches détectent les traits simples (bords, textures), les dernières les patterns complexes (types de défauts).

4.3 Configuration de l'entraînement

Hyperparamètre	Valeur
Optimiseur	Adam (lr = 1e-3)
Fonction de perte	Categorical Crossentropy

Métrique	Accuracy
Batch size	32
Époques max	50
EarlyStopping	patience = 10, monitor = val_loss
ReduceLROnPlateau	factor = 0.5, patience = 5

5. Résultats et Évaluation

5.1 Performance globale

Précision finale sur le jeu de test : 99.07%
214 images correctement classées sur 216

5.2 Analyse des erreurs

Sur les 216 images du jeu de test, le modèle n'a commis que 2 erreurs :

- 1 image de type **Crazing** classifiée comme **Rolled-in Scale** — visuellement similaires (patterns distribués)
- 1 image de type **Scratches** classifiée comme **Inclusion** — cas limite avec rayure fine ressemblant à une inclusion

5.3 Performance par classe

Classe	Vrais Positifs	Erreurs	Précision
Crazing	35/36	1	97.2%
Inclusion	36/36	0	100%
Patches	36/36	0	100%
Pitted Surface	36/36	0	100%
Rolled-in Scale	36/36	0	100%
Scratches	35/36	1	97.2%
TOTAL	214/216	2	99.07%

6. Interprétabilité — Grad-CAM

Grad-CAM (Gradient-weighted Class Activation Mapping) est une technique d'interprétabilité qui génère une carte de chaleur indiquant quelles régions de l'image ont le plus influencé la décision du modèle.

6.1 Principe de Grad-CAM

Pour une image d'entrée, Grad-CAM calcule le gradient du score de la classe prédite par rapport aux activations de la dernière couche convolutive (conv2d_3 dans notre modèle). Ces gradients sont moyennés pour obtenir des poids d'importance, puis multipliés par les feature maps pour produire la carte de chaleur finale.

6.2 Analyse qualitative des résultats

- **Images bien classifiées** : La carte Grad-CAM se concentre précisément sur la zone du défaut. Pour les "Scratches", la chaleur suit exactement les rayures verticales. Pour "Pitted Surface", elle se concentre sur les zones de cratères.
- **Images mal classifiées** : La carte Grad-CAM est uniforme (toute bleue), indiquant que le modèle n'a pas trouvé de zone discriminante claire, expliquant l'erreur de classification.
- **Conclusion** : Le modèle regarde les bonnes régions pour prendre ses décisions. Il ne se base pas sur des artefacts ou le fond de l'image, mais bien sur les caractéristiques visuelles distinctives de chaque type de défaut.

Importance de Grad-CAM pour le contrôle qualité industriel :

Dans un contexte industriel réel, il ne suffit pas que le modèle soit précis — il faut aussi pouvoir expliquer ses décisions aux opérateurs. Grad-CAM permet de valider que le modèle inspecte réellement la zone défectueuse, et non des artefacts d'image ou des caractéristiques non pertinentes. C'est essentiel pour la certification et l'acceptance du système en production.

7. Réseau Siamois et Visualisation t-SNE

En complément du CNN principal, nous avons implémenté un encodeur CNN partagé (réseau siamois simplifié) pour apprendre des représentations compactes des images de défauts.

7.1 Architecture de l'encodeur

Couche	Sortie
Conv2D(32) + MaxPool	112 × 112 × 32
Conv2D(64) + MaxPool	56 × 56 × 64
Conv2D(128) + MaxPool	28 × 28 × 128
GlobalAveragePooling2D	128
Dense(128)	Vecteur embedding dim. 128

7.2 Analyse des embeddings avec t-SNE

t-SNE (t-distributed Stochastic Neighbor Embedding) réduit les embeddings de dimension 128 à 2D pour la visualisation. La figure obtenue montre que :

- **Crazing (rouge)** : Cluster compact et bien séparé à gauche — très discriminant
- **Rolled-in Scale (violet)** : Cluster compact et bien isolé en haut
- **Scratches (vert clair)** : Plus dispersé, expliquant pourquoi c'est la seule classe avec une erreur
- **Pitted Surface et Inclusion** : Légèrement chevauchants dans l'espace d'embedding

7.3 Application à la détection d'anomalies

L'approche par réseau siamois et embeddings est particulièrement intéressante pour la détection de nouveaux types de défauts non vus lors de l'entraînement (anomaly detection). Un nouveau défaut dont l'embedding est éloigné de tous les clusters connus peut être automatiquement signalé comme anomalie, sans nécessiter de réentraînement du modèle.

8. Interface Web de Démonstration

Afin de rendre le modèle accessible et démontrable, nous avons développé une interface web interactive avec Gradio, déployée via un lien public.

8.1 Fonctionnalités

- Upload d'une image de surface métallique (glisser-déposer)
- Détection automatique du type de défaut avec le modèle CNN (99.07%)
- Affichage de la carte Grad-CAM superposée sur l'image originale
- Graphique des probabilités pour chaque classe de défaut
- Description textuelle du défaut détecté
- Interface responsive accessible depuis n'importe quel navigateur

8.2 Technologies utilisées

Composant	Technologie
Interface web	Gradio 4.x
Modèle IA	TensorFlow / Keras (CNN)
Interprétabilité	Grad-CAM (tf.GradientTape)
Traitement image	OpenCV, NumPy
Visualisation	Matplotlib
Hébergement	Gradio Share (lien public 7 jours)

9. Conclusion et Perspectives

9.1 Bilan du projet

Ce projet a permis de développer un système complet de détection automatique de défauts de surface sur pièces métalliques, atteignant une précision de 99.07% sur le jeu de test. Tous les objectifs pédagogiques fixés ont été atteints :

- ✓ Pipeline de traitement d'images industrielles en niveaux de gris
- ✓ Architecture CNN from scratch à 4 blocs convolutifs optimisée
- ✓ Pipeline d'augmentation adapté au contexte industriel (sans flip)
- ✓ Interprétabilité avec Grad-CAM — le modèle regarde les bonnes zones
- ✓ Réseau siamois avec visualisation t-SNE des embeddings
- ✓ Interface web interactive de démonstration (Gradio)

9.2 Limites identifiées

- **Dataset limité** : Seulement 1440 images d'entraînement — des datasets plus larges amélioreraient la robustesse.
- **Domaine spécifique** : Le modèle est entraîné uniquement sur l'acier — il faudrait le réentraîner pour d'autres matériaux.
- **Nouvelles classes** : Le modèle ne peut détecter que les 6 classes vues à l'entraînement.
- **Conditions d'éclairage** : Les images NEU ont des conditions d'acquisition contrôlées, pas toujours représentatives du terrain.

9.3 Perspectives d'amélioration

- Transfer Learning avec EfficientNet ou ResNet pré-entraîné sur ImageNet
- Détection d'anomalies avec One-Class SVM sur les embeddings du réseau siamois
- Déploiement sur edge device (Raspberry Pi + caméra) pour contrôle temps réel
- Intégration dans une chaîne de contrôle qualité avec alertes automatiques
- Augmentation du dataset par synthèse d'images (GAN)

Ce projet démontre la faisabilité et l'efficacité du Deep Learning pour l'automatisation du contrôle qualité industriel. Le système développé représente une base solide pour un déploiement en conditions réelles.